

مقدمة في تعلم الآلة

ملخصات علوم الحاسب، الجزء 4 من 6

1. ما هو تعلم الآلة؟

تعلم الآلة (Machine Learning) هو فرع من فروع الذكاء الاصطناعي يمكن الحاسوب من التعلم من البيانات دون الحاجة إلى برمجة قواعد صريحة لكل حالة. في البرمجة التقليدية يكتب المبرمج القواعد ثم يمرر البيانات ليحصل على النتائج. أما في تعلم الآلة فنعطي الخوارزمية البيانات والنتائج المعروفة، فتستنتج هي القواعد على شكل نموذج، ثم نستخدم هذا النموذج للتنبؤ ببيانات جديدة. من التطبيقات الشائعة تصنيف رسائل البريد الإلكتروني إلى مزعجة وعادية، والتنبؤ بأسعار العقارات، وأنظمة التوصية في المتاجر ومنصات الفيديو، والتعرف على الكلام والصور.

2. أنواع تعلم الآلة

ينقسم تعلم الآلة إلى ثلاثة أنواع رئيسية:

- التعلم الخاضع للإشراف (Supervised Learning): تكون البيانات مصحوبة بالإجابات الصحيحة، ويتعلم النموذج العلاقة بين المدخلات والمخرجات. ويشمل التصنيف، وهو التنبؤ بفئة مثل مزعج أو غير مزعج، والانحدار، وهو التنبؤ برقم مثل سعر منزل.
- التعلم غير الخاضع للإشراف (Unsupervised Learning): لا توجد إجابات جاهزة، ويبحث النموذج عن أنماط مخفية في البيانات. من أمثلته التجميع (Clustering)، مثل تقسيم العملاء إلى مجموعات متشابهة، وتقليل الأبعاد.
- التعلم المعزز (Reinforcement Learning): يتعلم وكيل ذكي عن طريق التجربة، فيحصل على مكافأة عند القرار الجيد وعلى عقوبة عند القرار السيئ. يستخدم في الألعاب والروبوتات.

3. تقسيم البيانات والحفظ الزائد

لا يجوز تقييم النموذج على نفس البيانات التي تدرب عليها، لأن ذلك يعطي صورة مضللة. لذلك نقسم البيانات عادة إلى مجموعة تدريب ومجموعة اختبار، وأشهر نسبة تقسيم هي 80 بالمئة للتدريب و20 بالمئة للاختبار، وأحيانا 70 بالمئة و30 بالمئة. وقد نصيف مجموعة تحقق (Validation) لضبط الإعدادات قبل الاختبار النهائي.

الحفظ الزائد (Overfitting) يحدث عندما يحفظ النموذج بيانات التدريب بما فيها من ضوضاء، فيكون ممتازا على بيانات التدريب وضعيفا على البيانات الجديدة. أما عدم الملاءمة (Underfitting) فيحدث عندما يكون النموذج أبسط من أن يلتقط النمط في البيانات، فيكون ضعيفا على بيانات التدريب والاختبار معا.

من طرق علاج الحفظ الزائد: جمع بيانات أكثر، وتبسيط النموذج، واستخدام التنظيم (Regularization)، والإيقاف المبكر للتدريب، واستخدام التحقق المتقاطع (Cross-Validation) الذي يقسم البيانات إلى عدة أجزاء ويدرب النموذج ويختبره عدة مرات.

4. مقاييس تقييم نماذج التصنيف

الدقة (Accuracy) هي نسبة التنبؤات الصحيحة من مجموع التنبؤات. لكنها قد تكون مضللة عندما تكون الفئات غير متوازنة. لذلك نستخدم مقاييس إضافية تعتمد على أربعة أرقام: الإيجابي الصحيح TP، والإيجابي الخاطئ FP، والسليبي الصحيح TN، والسليبي الخاطئ FN.

$$\begin{aligned}\text{Accuracy} &= (TP + TN) / (TP + TN + FP + FN) \\ \text{Precision} &= TP / (TP + FP) \\ \text{Recall} &= TP / (TP + FN) \\ \text{F1} &= 2 * \text{Precision} * \text{Recall} / (\text{Precision} + \text{Recall})\end{aligned}$$

الدقة الموجبة (Precision) تجيب عن السؤال: من بين ما توقعه النموذج إيجابيا، كم كان صحيحا فعلا؟ والاستدعاء (Recall) يجيب عن السؤال: من بين كل الحالات الإيجابية الحقيقية، كم حالة اكتشفها النموذج؟ ومقياس F1 هو المتوسط التوافقي لهما، ويفيد عندما نريد توازنا بين المقياسين. مثال: إذا كانت TP تساوي 40 و FP تساوي 10 و FN تساوي 20 و TN تساوي 30، فإن المجموع 100 والدقة 0.70. وتكون Precision تساوي 0.80 و Recall تساوي 0.67 تقريبا و F1 تساوي 0.73 تقريبا.

5. خوارزميات شائعة والنزول التدريجي

من الخوارزميات الشائعة: الانحدار الخطي (Linear Regression) للتنبؤ بقيم رقمية، والانحدار اللوجستي (Logistic Regression) للتصنيف، وأشجار القرار (Decision Trees)، والغابة العشوائية (Random Forest) التي تجمع عدة أشجار قرار، وخوارزمية أقرب الجيران (KNN)، وخوارزمية K-Means للتجميع.

النزول التدريجي (Gradient Descent) هو طريقة لتدريب النماذج تعدل فيها الأوزان خطوة بعد خطوة لتقليل دالة الخسارة. يتحكم معدل التعلم (Learning Rate) في حجم كل خطوة: إذا كان كبيرا جدا فقد يتجاوز النموذج الحل الأفضل ولا يستقر، وإذا كان صغيرا جدا فسيكون التدريب بطيئا جدا.

تسير مراحل مشروع تعلم الآلة عادة كما يلي: تحديد المشكلة، ثم جمع البيانات وتنظيفها، ثم تقسيمها، ثم تدريب النموذج، ثم تقييمه، ثم نشره ومراقبة أدائه.